LAPORAN FINAL PROJECT PEMBELAJARAN MESIN SEMESTER GENAP 2025/2026

IDENTITAS PROYEK	
Judul	Deteksi Promosi Judi Online pada Komentar YouTube Berbahasa Indonesia Menggunakan Support Vector Machine dan Multilayer Perceptron dengan Normalisasi Character Obfuscation
Topik	Natural Language Processing (NLP) dan Klasifikasi Teks
Identitas Penyusun	1. Nadine Putri Aulia (24031554094) 2. Umi Imroatus Sholekhah (24031554150) 3. Satya Apta Mahardika (24031554024) 4. Fawazul Ammar (24031554136)
Kelas	2024B

1. PENDAHULUAN

1.1 Latar Belakang

Perkembangan media sosial, khususnya YouTube, telah menjadikannya sebagai salah satu platform utama dalam penyebaran informasi dan interaksi antar pengguna. Namun, meningkatnya aktivitas pengguna juga diikuti oleh munculnya komentar yang mengandung promosi judi online. Komentar tersebut sering disebarkan secara masif pada kolom komentar video sehingga mengganggu kenyamanan pengguna dan melanggar kebijakan platform digital. Kondisi ini mendorong perlunya sistem otomatis yang mampu mendeteksi komentar promosi judi online secara efektif menggunakan pendekatan *machine learning* (Samuel & Kristiadi, 2025).

Berbagai penelitian menunjukkan bahwa pendekatan *Natural Language Processing* (NLP) dan *machine learning* dapat digunakan untuk mendeteksi komentar promosi judi online. Algoritma seperti *Support Vector Machine* (SVM), *Random Forest*, dan *Transformer* telah diterapkan pada klasifikasi komentar media sosial, namun performanya sangat dipengaruhi oleh kualitas *preprocessing* data (Arroyana et al., 2026). Selain itu, komentar promosi judi online sering menggunakan variasi penulisan tertentu untuk menghindari deteksi otomatis sehingga menjadi tantangan dalam proses klasifikasi teks (Perdana et al., 2024; Ode et al., 2026; Tjahyadi et al., 2023).

Salah satu tantangan utama adalah penggunaan *character obfuscation*, yaitu teknik penyamaran teks melalui karakter Unicode, simbol dekoratif, maupun substitusi huruf dengan angka. Teknik tersebut dapat menyebabkan model kesulitan mengenali kata yang sebenarnya memiliki makna yang sama (Alazab et al., 2022). Oleh karena itu, kualitas *preprocessing* dan normalisasi teks menjadi faktor penting dalam meningkatkan kualitas representasi data untuk proses klasifikasi (Rifaldi et al., 2023).

Berdasarkan permasalahan tersebut, penelitian ini mengusulkan deteksi komentar promosi judi online pada YouTube berbahasa Indonesia menggunakan algoritma *Support Vector Machine* (SVM) dan *Multilayer Perceptron* (MLP) dengan tambahan normalisasi *character obfuscation*. Penelitian ini bertujuan mengevaluasi pengaruh normalisasi teks terhadap performa klasifikasi serta membandingkan kinerja kedua algoritma dalam mendeteksi komentar promosi judi online (Antonius et al., 2024; Arasy et al., 2025; Alamsyah & Hermawan, 2024).

1.2 Pendekatan pemecahan masalah

Pendekatan pemecahan masalah dalam penelitian ini dilakukan dengan membangun sistem klasifikasi teks berbasis *Natural Language Processing* (NLP) untuk mendeteksi komentar promosi judi online pada platform YouTube. Sistem dirancang untuk mengatasi permasalahan variasi penulisan teks dan penggunaan *character obfuscation* yang sering dimanfaatkan untuk menghindari deteksi otomatis.

Tahap awal penelitian dilakukan dengan mengolah dataset komentar YouTube berbahasa Indonesia yang diperoleh dari Kaggle. Data kemudian melalui proses *data cleaning* dan *text preprocessing* untuk meningkatkan kualitas data. Penelitian ini menggunakan tiga skenario *preprocessing*, yaitu *Standard Preprocessing*, *Advanced Preprocessing*, dan *Dataset Clean Preprocessing*. Pada *Advanced Preprocessing* diterapkan beberapa proses normalisasi tambahan, seperti *Unicode normalization*, *spaced-character merging*, *leetspeak normalization*, dan *symbol replacement* untuk membantu mengenali berbagai bentuk *obfuscation* pada komentar promosi judi online.

Selanjutnya, data teks direpresentasikan ke dalam bentuk numerik menggunakan metode TF-IDF sebelum dilakukan proses klasifikasi menggunakan algoritma *Support Vector Machine* (SVM) dan *Multilayer Perceptron* (MLP). Performa kedua model kemudian dievaluasi menggunakan *accuracy*, *precision*, *recall*, dan *F1-score*, serta dibandingkan untuk mengetahui pengaruh skenario *preprocessing* terhadap kemampuan model dalam mendeteksi komentar promosi judi online.

2. Metodologi

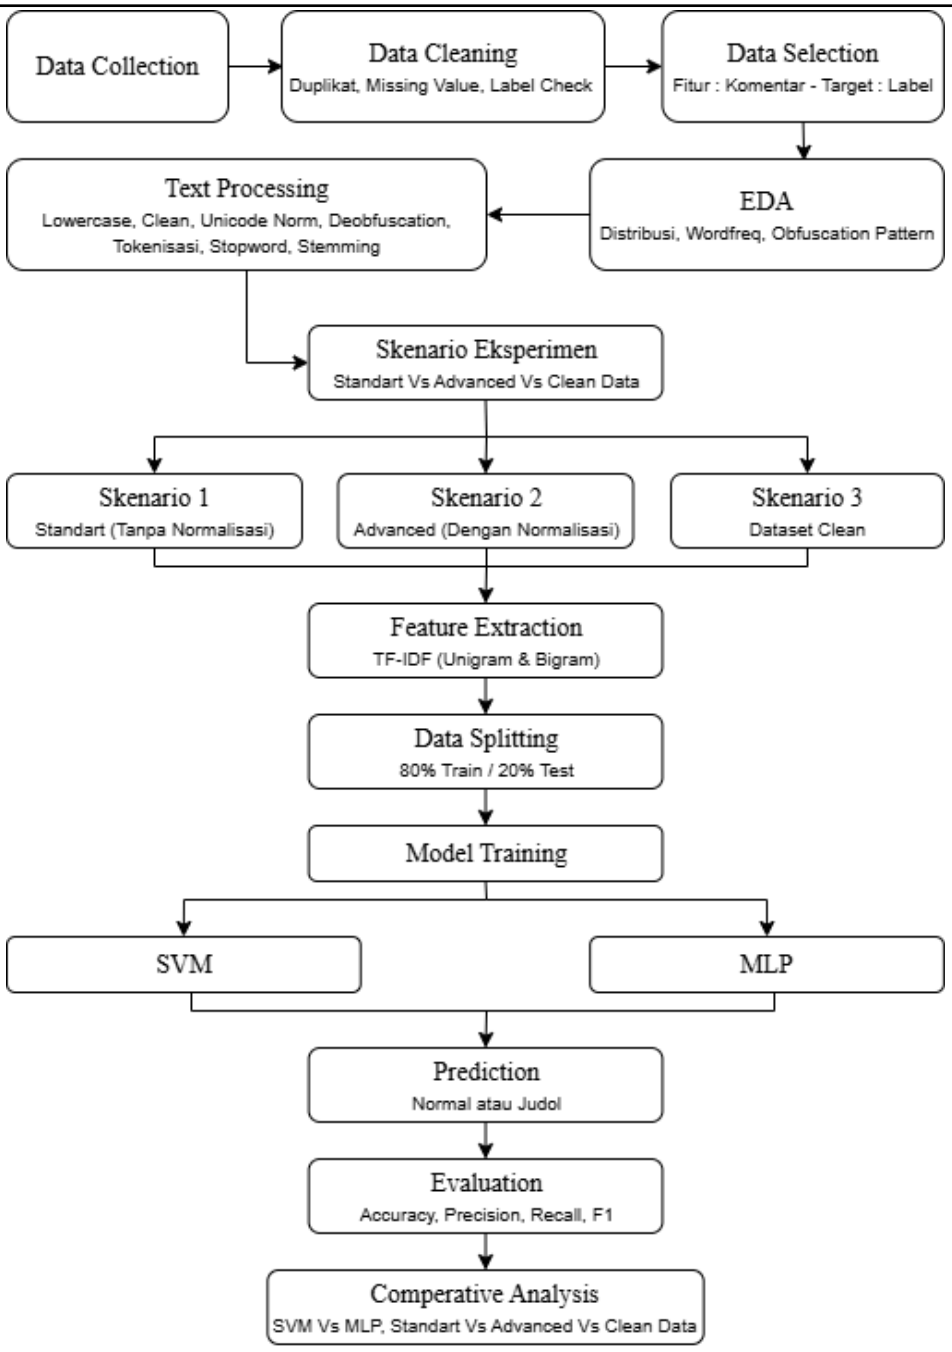
2.1 Eksplorasi Dataset

Dataset yang digunakan dalam penelitian ini merupakan dataset komentar YouTube berbahasa Indonesia yang diperoleh dari platform Kaggle dengan nama dataset *Judi Online* (Yaemico, 2024). Dataset tersebut berisi komentar yang telah diberi label ke dalam dua kategori, yaitu komentar normal dan komentar promosi judi online (judol). Secara keseluruhan dataset awal terdiri dari 10.230 data komentar dengan 9 atribut, yaitu *video_id*, *title*, *channel_name*, *tanggal*, *author*, *komentar*, *label*, *komentar_clean*, dan *predicted_label*.

Pada penelitian ini digunakan empat atribut utama, yaitu komentar, label, komentar_clean, dan tanggal. Atribut *komentar* digunakan sebagai data teks utama yang akan diproses dan diklasifikasikan, atribut *label* digunakan sebagai target klasifikasi, sedangkan atribut *komentar_clean* digunakan pada skenario *Dataset Clean Preprocessing*. Label 0 merepresentasikan komentar normal, sedangkan label 1 merepresentasikan komentar promosi judi online. Atribut tanggal digunakan untuk analisis tren temporal kemunculan komentar promosi judi online.

Sebelum proses pemodelan dilakukan, dataset terlebih dahulu melalui tahap *data cleaning* untuk menghapus data yang tidak valid dan komentar duplikat. Setelah proses pembersihan data, jumlah data berkurang dari 10.230 komentar menjadi 9.001 komentar yang selanjutnya digunakan pada seluruh tahapan penelitian.

2.2 Tahapan Penelitian



Gambar 1. Tahapan Penelitian

1. **Pengumpulan Data**
   Dataset diperoleh dari Kaggle dengan nama dataset "Judi Online" yang berisi komentar YouTube berbahasa Indonesia yang telah dilabeli secara manual. Kolom yang digunakan dalam penelitian ini adalah *komentar* sebagai fitur input dan *label* sebagai target klasifikasi , dengan label 0 untuk komentar normal dan label 1 untuk komentar promosi judi online.
2. **Data Cleaning**
   Tahap data cleaning dilakukan untuk memastikan kualitas data sebelum diproses lebih lanjut. Proses ini meliputi penghapusan data duplikat, penanganan missing value, pengecekan konsistensi label, serta pemeriksaan distribusi kelas pada dataset.
3. **Seleksi Data**
   Pada tahap ini dilakukan pemilihan atribut yang digunakan dalam penelitian. Kolom yang digunakan hanya kolom komentar dan label. Kolom komentar dipilih karena berisi teks utama yang akan dianalisis, sedangkan label digunakan sebagai target klasifikasi.

4. **Pengumpulan Data**
   Dataset diperoleh dari Kaggle dengan nama dataset "Judi Online" yang berisi komentar YouTube berbahasa Indonesia yang telah dilabeli secara manual. Kolom yang digunakan dalam penelitian ini adalah *komentar* sebagai fitur input dan *label* sebagai target klasifikasi , dengan label 0 untuk komentar normal dan label 1 untuk komentar promosi judi online.
5. **Data Cleaning**
   Tahap data cleaning dilakukan untuk memastikan kualitas data sebelum diproses lebih lanjut. Proses ini meliputi penghapusan data duplikat, penanganan missing value, pengecekan konsistensi label, serta pemeriksaan distribusi kelas pada dataset.
6. **Seleksi Data**
   Pada tahap ini dilakukan pemilihan atribut yang digunakan dalam penelitian. Kolom yang digunakan hanya kolom komentar dan label. Kolom komentar dipilih karena berisi teks utama yang akan dianalisis, sedangkan label digunakan sebagai target klasifikasi.
7. **Exploratory Data Analysis (EDA)**
   EDA dilakukan untuk memahami karakteristik dataset sebelum proses pemodelan dilakukan. Analisis meliputi distribusi label, panjang komentar, frekuensi kata yang sering muncul pada masing-masing kelas, pola kata promosi judi online, serta pola character obfuscation seperti penggunaan angka, simbol, dan unicode stylized text pada komentar.
8. **Text Preprocessing**
   Tahap preprocessing merupakan bagian utama dalam penelitian ini. Proses preprocessing dilakukan secara bertahap meliputi lowercase, cleaning, unicode normalization, penghapusan simbol dekoratif, character obfuscation normalization, tokenization, stopword removal, dan stemming menggunakan library Sastrawi. Pada tahap normalisasi, beberapa karakter yang disamarkan akan diubah ke bentuk standar agar kata dengan makna sama dapat dikenali sebagai kata yang sama oleh model machine learning.
9. **Skenario Eksperimen**
   Penelitian ini menggunakan tiga skenario preprocessing. Skenario pertama menggunakan *standard preprocessing* tanpa normalisasi *character obfuscation*. Skenario kedua menggunakan *advanced preprocessing* dengan normalisasi karakter dan *unicode normalization*. Skenario ketiga menggunakan *dataset clean preprocessing* dengan memanfaatkan kolom komentar_clean yang telah tersedia pada dataset. Ketiga skenario digunakan untuk mengetahui pengaruh preprocessing terhadap performa klasifikasi komentar promosi judi online.
10. **Feature Extraction**
    Representasi teks dilakukan menggunakan metode TF-IDF dengan unigram dan bigram. Penggunaan unigram dan bigram bertujuan untuk menangkap hubungan antar kata yang sering muncul pada komentar promosi judi online. Hasil ekstraksi fitur kemudian diubah menjadi representasi numerik yang dapat diproses oleh model *machine learning*.
11. **Pembagian Data**
    Dataset dibagi menjadi data training dan data testing dengan rasio 80:20 menggunakan stratified split agar proporsi label pada kedua data tetap seimbang.
12. **Pelatihan Model**
    Penelitian ini menggunakan dua algoritma klasifikasi, yaitu Support Vector Machine (SVM) dan Multilayer Perceptron (MLP). SVM dipilih karena memiliki performa yang baik pada klasifikasi teks berbasis TF-IDF, sedangkan MLP digunakan karena mampu mempelajari pola non-linear pada data teks.
13. **Prediksi & Evaluasi**

Model yang telah dilatih kemudian digunakan untuk memprediksi data testing ke dalam kategori normal atau judol. Evaluasi dilakukan menggunakan accuracy, precision, recall, F1-score, dan confusion matrix. Recall menjadi fokus utama karena komentar judol yang tidak terdeteksi dapat menyebabkan promosi judi online tetap tersebar pada platform.

14. **Comparative Analysis**
    Tahap terakhir dilakukan perbandingan performa antara algoritma SVM dan MLP pada seluruh skenario preprocessing. Analisis dilakukan berdasarkan nilai evaluasi, *runtime*, hasil *confusion matrix*, serta pengaruh preprocessing terhadap kemampuan model dalam mendeteksi komentar promosi judi online

2.3 Analisis Data Eksploratif

Analisis Data Eksploratif (*Exploratory Data Analysis* atau EDA) dilakukan untuk memahami karakteristik dataset sebelum proses preprocessing dan pemodelan dilakukan (Arroyana et al., 2026). Analisis ini mencakup distribusi label untuk mengetahui komposisi kelas pada dataset, analisis panjang komentar untuk mengidentifikasi karakteristik teks pada masing-masing kelas, analisis pola *character obfuscation* untuk mengidentifikasi bentuk penyamaran teks yang digunakan pada komentar promosi judi online, serta analisis frekuensi *spam keyword* untuk mengetahui kata atau istilah yang sering muncul pada komentar tersebut (Perdana et al., 2024; Alazab et al., 2022).

Selain itu, EDA juga dilakukan melalui visualisasi *word cloud*, analisis frekuensi kata (*top frequent words*), dan analisis pasangan kata (*bigram*) untuk memperoleh gambaran pola penggunaan kata pada dataset (Samuel & Kristiadi, 2025). Hasil dari tahapan EDA digunakan sebagai dasar dalam menentukan strategi preprocessing yang sesuai sebelum proses klasifikasi dilakukan, khususnya untuk menangani variasi penulisan dan pola *character obfuscation* yang umum ditemukan pada komentar promosi judi online (Alazab et al., 2022; Alamsyah & Hermawan, 2024).

2.4 Text Preprocessing

2.4.1 Standard Preprocessing

Standard preprocessing merupakan skenario dasar pembersihan teks yang bertujuan mengubah komentar mentah menjadi representasi yang lebih konsisten dan siap diproses oleh model *machine learning* (Rifaldi et al., 2023). Tahapan yang diterapkan meliputi *lowercase* untuk menyeragamkan huruf, penghapusan URL, *mention*, *hashtag*, tanda baca, dan karakter non-alfanumerik menggunakan *regular expression* (regex). Selanjutnya dilakukan proses tokenisasi menggunakan fungsi .split(), *stopword removal* menggunakan daftar *stopword* Bahasa Indonesia dari library NLTK, serta *stemming* menggunakan library Sastrawi untuk mengubah kata berimbuhan menjadi bentuk kata dasar (Rifaldi et al., 2023; Antonius et al., 2024).

Skenario ini tidak menerapkan normalisasi *character obfuscation* sehingga digunakan sebagai dasar perbandingan terhadap skenario *preprocessing* lainnya. Keterbatasan utama pendekatan ini adalah belum mampu menangani berbagai bentuk penyamaran teks yang sering digunakan pada komentar promosi judi online, karena sebagian karakter Unicode dan simbol dekoratif dapat mengalami perubahan atau penghapusan selama proses pembersihan teks. Akibatnya, beberapa kata yang memiliki makna sama dapat direpresentasikan sebagai bentuk yang berbeda sehingga berpotensi memengaruhi proses klasifikasi (Alazab et al., 2022).

2.4.2 Advanced Preprocessing

Advanced preprocessing merupakan pengembangan dari standard preprocessing yang dirancang untuk menangani berbagai bentuk *character obfuscation* yang umum ditemukan pada komentar promosi judi online (Alamsyah & Hermawan, 2024). Tahapan tambahan yang diterapkan meliputi *Unicode normalization* menggunakan metode NFKD melalui fungsi unicodedata.normalize() untuk mengonversi karakter stylized menjadi bentuk ASCII standar, penghapusan simbol dekoratif dan emoji menggunakan regex, *word-number normalization* untuk mengonversi kata angka ke bentuk digit, *spaced-character merging* untuk menggabungkan karakter yang dipisahkan spasi, *character deobfuscation* untuk mengembalikan simbol ke bentuk huruf yang sesuai, serta normalisasi *leetspeak* secara selektif menggunakan aturan berbasis regex (Alazab et al., 2022; Alamsyah & Hermawan, 2024; Rifaldi et al., 2023).

Skenario ini digunakan untuk menganalisis pengaruh normalisasi *character obfuscation* terhadap performa model klasifikasi. Dengan adanya tahapan normalisasi tambahan tersebut, berbagai variasi penulisan komentar yang menggunakan karakter Unicode, simbol dekoratif, maupun substitusi huruf dan angka dapat direpresentasikan dalam bentuk yang lebih seragam sehingga diharapkan membantu model mengenali pola komentar promosi judi online dengan lebih baik (Alazab et al., 2022; Antonius et al., 2024).

2.4.3 Dataset Clean Preprocessing

Dataset clean preprocessing merupakan salah satu skenario preprocessing yang menggunakan kolom komentar_clean yang telah tersedia pada dataset. Tahap preprocessing dilakukan untuk membersihkan teks komentar agar data menjadi lebih terstruktur dan siap digunakan pada proses klasifikasi. Tahapan preprocessing pada text mining memiliki peran penting karena data media sosial umumnya masih mengandung noise, simbol, kata tidak baku, dan karakter yang tidak diperlukan (Rifaldi et al., 2023).

Pada penelitian ini, dataset clean preprocessing dilakukan melalui beberapa tahapan, yaitu mengubah teks menjadi huruf kecil (*lowercase*), menghapus spasi berlebih, tokenisasi, stopword removal, dan stemming menggunakan library Sastrawi. Tahapan tersebut bertujuan untuk menyederhanakan bentuk kata sehingga representasi teks menjadi lebih konsisten dan mudah diproses oleh model machine learning. Proses preprocessing diketahui dapat meningkatkan kualitas data teks sebelum masuk ke tahap klasifikasi (Ode et al., 2026).

Hasil preprocessing ini kemudian digunakan sebagai salah satu skenario pembanding terhadap standard preprocessing dan advanced preprocessing pada proses klasifikasi komentar promosi judi online menggunakan algoritma SVM dan MLP.

2.5 TF-IDF Vectorization

TF-IDF (Term Frequency-Inverse Document Frequency) digunakan untuk mengubah data teks hasil preprocessing menjadi representasi numerik yang dapat diproses oleh algoritma machine learning. Metode ini memberikan bobot pada setiap kata berdasarkan frekuensi kemunculannya dalam dokumen serta tingkat kelangkaannya pada seluruh dokumen. Dengan demikian, kata-kata yang lebih informatif akan memiliki bobot yang lebih tinggi dibandingkan kata-kata yang sering muncul pada banyak dokumen. Penggunaan TF-IDF telah banyak diterapkan dalam penelitian klasifikasi teks karena mampu merepresentasikan karakteristik dokumen secara efektif (Rifaldi et al., 2023; Antonius et al., 2024).

Pada penelitian ini, fitur yang digunakan mencakup unigram dan bigram untuk menangkap informasi dari kata tunggal maupun kombinasi dua kata yang berurutan. Selain itu, jumlah fitur dibatasi pada 10.000 fitur teratas guna mengurangi kompleksitas komputasi sekaligus mempertahankan informasi yang paling relevan. Proses TF-IDF diterapkan pada tiga skenario preprocessing, yaitu Standard Preprocessing, Advanced Preprocessing, dan Dataset Clean Preprocessing, yang selanjutnya digunakan sebagai masukan bagi algoritma SVM dan MLP dalam proses klasifikasi komentar YouTube.

2.6 Train-Test Split

Pembagian data dilakukan untuk memisahkan dataset menjadi data pelatihan (*training*) dan data pengujian (*testing*) menggunakan rasio 80:20 melalui fungsi train_test_split dari library *scikit-learn*. Parameter stratifikasi diterapkan untuk memastikan proporsi label pada data training dan testing tetap seimbang sesuai distribusi kelas asli, mengingat distribusi data komentar normal dan komentar judol tidak seimbang. Tanpa proses stratifikasi, pembagian data secara acak berisiko menghasilkan subset data yang tidak merepresentasikan distribusi kelas asli sehingga dapat memengaruhi kualitas pelatihan dan evaluasi model (Tjahyadi et al., 2023).

Pembagian data dilakukan secara terpisah pada setiap skenario preprocessing. Data training selanjutnya digunakan pada proses pelatihan model, sedangkan data testing digunakan untuk mengevaluasi performa model klasifikasi SVM dan MLP (Ode et al., 2026).

2.7 Algoritma SVM

Support Vector Machine (SVM) merupakan salah satu algoritma *supervised learning* yang banyak digunakan dalam tugas klasifikasi teks. SVM bekerja dengan mencari *hyperplane* optimal yang mampu memisahkan data dari kelas yang berbeda dengan margin maksimum. Pendekatan tersebut membuat SVM memiliki kemampuan yang baik dalam menangani data berdimensi tinggi, termasuk data teks yang telah direpresentasikan dalam bentuk fitur TF-IDF. Oleh karena itu, SVM sering digunakan pada berbagai penelitian klasifikasi teks dan deteksi spam karena mampu menghasilkan performa yang baik dan stabil (Antonius et al., 2024; Tjahyadi et al., 2023).

Pada penelitian ini, SVM digunakan sebagai salah satu algoritma klasifikasi untuk mendeteksi komentar promosi judi online pada platform YouTube. Model dibangun menggunakan fitur TF-IDF yang dihasilkan dari tiga skenario preprocessing, yaitu Standard Preprocessing, Advanced Preprocessing, dan Dataset Clean Preprocessing. Selanjutnya, performa model dievaluasi menggunakan metrik accuracy, precision, recall, dan F1-score untuk mengukur kemampuan model dalam membedakan komentar normal dan komentar yang mengandung promosi judi online.

2.8 Algoritma MLP

Multilayer Perceptron (MLP) merupakan salah satu algoritma jaringan saraf tiruan (*Artificial Neural Network*) yang terdiri atas lapisan input, satu atau lebih lapisan tersembunyi (*hidden layer*), dan lapisan output. MLP mampu mempelajari hubungan yang kompleks dan nonlinier antar fitur melalui proses pembelajaran berbasis *backpropagation*. Kemampuan tersebut menjadikan MLP banyak digunakan dalam berbagai tugas klasifikasi teks dan Natural Language Processing (NLP). Pendekatan machine learning pada klasifikasi komentar spam dan promosi judi online juga telah banyak digunakan pada penelitian sebelumnya dan menunjukkan performa yang cukup baik (Ode et al., 2026; Tjahyadi et al., 2023).

Pada penelitian ini, MLP digunakan sebagai algoritma pembanding terhadap Support Vector Machine (SVM) dalam mendeteksi komentar promosi judi online pada platform YouTube. Model dibangun menggunakan fitur TF-IDF yang dihasilkan dari tiga skenario preprocessing, yaitu *Standard Preprocessing*, *Advanced Preprocessing*, dan *Dataset Clean Preprocessing*. Selanjutnya, performa model dievaluasi menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score* untuk mengukur kemampuan model dalam mengklasifikasikan komentar normal dan komentar yang mengandung promosi judi online.

2.9 Evaluasi dan Perbandingan Model

Evaluasi model dilakukan untuk mengukur kemampuan algoritma dalam mengklasifikasikan komentar YouTube ke dalam kategori komentar normal dan komentar yang mengandung promosi judi online. Pada penelitian ini, performa model dievaluasi menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. *Accuracy* digunakan untuk mengukur proporsi prediksi yang benar terhadap seluruh data, *precision* digunakan untuk mengukur ketepatan model dalam mengidentifikasi komentar promosi judi online, *recall* digunakan untuk mengukur kemampuan model dalam menemukan seluruh komentar promosi judi online, sedangkan *F1-score* digunakan untuk memberikan keseimbangan antara nilai *precision* dan *recall*.

Selain menggunakan metrik evaluasi utama, penelitian ini juga memanfaatkan *confusion matrix* untuk menganalisis distribusi prediksi benar dan salah pada masing-masing kelas. Penggunaan evaluasi klasifikasi dan *confusion matrix* umum digunakan pada penelitian deteksi spam komentar media sosial dan klasifikasi teks berbasis *machine learning* (Ode et al., 2026; Tjahyadi et al., 2023). Pada penelitian ini, evaluasi dilakukan pada seluruh kombinasi model dan skenario preprocessing, yaitu *Standard Preprocessing*, *Advanced Preprocessing*, dan *Dataset Clean Preprocessing* untuk mengetahui pengaruh preprocessing terhadap performa klasifikasi komentar promosi judi online.

Selain evaluasi performa model, penelitian ini juga melakukan *cross validation*, *runtime comparison*, dan *error analysis* untuk mengetahui kestabilan model serta menganalisis komentar yang salah diprediksi oleh model. Analisis tersebut dilakukan untuk mengetahui pengaruh *character obfuscation*, variasi penulisan, serta penggunaan simbol tertentu terhadap hasil klasifikasi komentar promosi judi online.

2.10 Pemilihan Model Terbaik

Pemilihan model terbaik merupakan tahap penting dalam penelitian machine learning yang bertujuan untuk menentukan kombinasi model dan skenario preprocessing yang paling optimal dalam menyelesaikan permasalahan klasifikasi. Pemilihan model terbaik tidak hanya didasarkan pada satu metrik evaluasi saja, melainkan mempertimbangkan berbagai aspek secara menyeluruh agar model yang dipilih benar-benar mampu memberikan performa terbaik pada data yang belum pernah dilihat sebelumnya.

Pada penelitian ini, pemilihan model terbaik akan dilakukan berdasarkan beberapa kriteria utama. Pertama, performa klasifikasi yang diukur menggunakan metrik accuracy, precision, recall, dan F1-score. Recall menjadi fokus utama karena komentar judol yang tidak terdeteksi (false negative) dapat menyebabkan promosi judi online tetap tersebar pada platform. Kedua, kestabilan model yang diukur menggunakan hasil 5-fold cross validation, di mana model dengan nilai rata-rata F1-score tertinggi dan variansi antar fold yang rendah dianggap memiliki kemampuan

generalisasi yang lebih baik. Ketiga, analisis confusion matrix untuk melihat distribusi prediksi benar dan salah pada masing-masing kelas secara lebih rinci. Keempat, efisiensi komputasi yang diukur dari waktu komputasi (runtime) selama proses pelatihan dan prediksi model. Model yang mampu menghasilkan performa tinggi dengan waktu komputasi yang lebih efisien akan menjadi pertimbangan tambahan dalam pemilihan model terbaik.

2.11 Analisis dan Interpretasi Hasil

Tahap analisis dan interpretasi hasil bertujuan untuk mengkaji secara mendalam performa model klasifikasi yang telah dibangun, serta memahami pengaruh masing-masing skenario preprocessing terhadap kemampuan model dalam mendeteksi komentar promosi judi online. Analisis dilakukan secara menyeluruh dengan membandingkan hasil evaluasi antar model dan antar skenario preprocessing menggunakan metrik accuracy, precision, recall, dan F1-score.

Pada tahap ini akan dianalisis pengaruh skenario preprocessing terhadap performa model, di mana hasil evaluasi dari ketiga skenario yaitu Standard Preprocessing, Advanced Preprocessing, dan Dataset Clean Preprocessing akan dibandingkan untuk melihat sejauh mana normalisasi character obfuscation berkontribusi terhadap peningkatan performa klasifikasi. Selain itu, perbandingan antar algoritma juga akan dilakukan untuk mengetahui apakah SVM atau MLP yang lebih efektif dalam menangani data teks berbasis TF-IDF pada kasus deteksi komentar promosi judi online.

Analisis juga akan mencakup hasil cross validation untuk mengevaluasi kestabilan dan kemampuan generalisasi model, hasil confusion matrix untuk memahami distribusi prediksi benar dan salah pada masing-masing kelas, serta error analysis untuk mengidentifikasi pola kesalahan klasifikasi yang masih terjadi. Seluruh hasil analisis tersebut kemudian akan diinterpretasikan untuk menghasilkan kesimpulan yang komprehensif mengenai efektivitas pendekatan yang diusulkan dalam penelitian ini.

3. Hasil dan Pembahasan

3.1 Karakteristik Dataset

Pada tahap awal penelitian dilakukan proses seleksi data dan cleaning untuk memastikan kualitas dataset sebelum digunakan pada tahap preprocessing dan feature extraction.

3.1.1 Seleksi Data

Tahap seleksi data dilakukan untuk memilih atribut yang relevan dengan tujuan penelitian. Dataset awal terdiri dari 9 atribut, yaitu *video_id*, *title*, *channel_name*, *tanggal*, *author*, *komentar*, *label*, *komentar_clean*, dan *predicted_label*. Namun, tidak seluruh atribut digunakan dalam proses klasifikasi.

Pada penelitian ini hanya digunakan tiga atribut utama, yaitu *komentar*, *label*, dan *komentar_clean*. Atribut *komentar* digunakan sebagai data teks utama yang akan diproses dan diklasifikasikan, atribut *label* digunakan sebagai target klasifikasi, sedangkan atribut *komentar_clean* digunakan pada skenario *Dataset Clean Preprocessing*. Hasil seleksi data ditunjukkan pada Tabel 1.

Tabel 1. Hasil Seleksi Data

komentar	label	komentar_clean
Makin yakin abis baca review lain tentang ✌✌ **SGI88**	1	makin yakin abis baca review lain tentang **SGI88** .

Paling suka model H2 😍🔥	0	suka model h2
Mobilnya udah hancur 🥺	0	mobilnya udah hancur
▒***MANUT***88▒benar2 bikin aku jadi sultan	1	▒***MANUT***88▒benar2 bikin sultan

Dari hasil seleksi data terlihat bahwa komentar promosi judi online umumnya mengandung nama situs tertentu, penggunaan karakter Unicode stylized text, serta kombinasi huruf dan angka sebagai bentuk *character obfuscation*. Sementara itu, komentar normal lebih banyak berisi tanggapan terhadap isi video dan tidak mengandung unsur promosi. Karakteristik tersebut menjadi dasar dalam perancangan tahapan *preprocessing* dan proses klasifikasi pada penelitian ini.

3.1.2 Data Cleaning

Setelah proses seleksi data, dilakukan tahap *data cleaning* untuk meningkatkan kualitas dataset sebelum digunakan pada proses preprocessing teks. Tahap *cleaning* meliputi penghapusan *missing value* pada kolom komentar dan label, validasi tipe data label menjadi integer, penyaringan label agar hanya menggunakan label valid yaitu 0 (normal) dan 1 (judol), penghapusan komentar duplikat, serta *reset index* dataset.

Tabel 2. Hasil Data Cleaning Dataset

Keterangan	Nilai
Jumlah Data Awal	10.230
Jumlah Atribut Awal	9
Jumlah Data Setelah Cleaning	9.001
Jumlah Atribut Digunakan	3

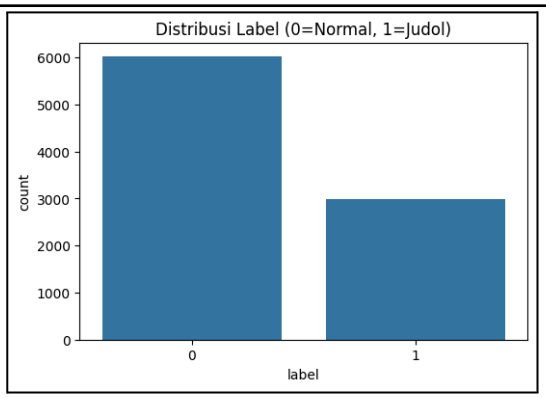
Berdasarkan hasil *cleaning*, jumlah data berkurang dari 10.230 komentar menjadi 9.001 komentar. Pengurangan jumlah data terutama disebabkan oleh penghapusan komentar duplikat yang memiliki isi komentar yang sama. Selain itu, hanya tiga atribut utama yang digunakan dalam penelitian, yaitu komentar, label, dan komentar_clean. Proses *cleaning* dilakukan untuk mengurangi *noise* serta meningkatkan konsistensi data sebelum memasuki tahap preprocessing dan klasifikasi.

3.1.3 Distribusi Label

Analisis distribusi label dilakukan untuk mengetahui komposisi kelas pada dataset yang digunakan dalam penelitian. Informasi ini penting karena distribusi kelas dapat memengaruhi proses pelatihan dan evaluasi model klasifikasi.

Tabel 3. Distribusi Label Dataset

Label	Kategori	Jumlah
0	Normal	6.018
1	Judol	2.983



Gambar 2. Distribusi Label

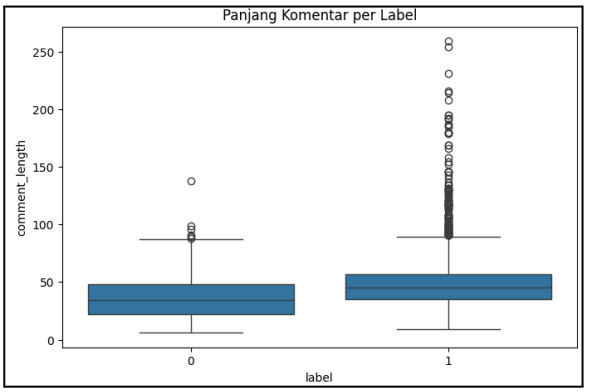
Berdasarkan Tabel 3, dataset didominasi oleh komentar normal sebanyak 6.018 data (66,86%), sedangkan komentar promosi judi online berjumlah 2.983 data (33,14%). Meskipun distribusi kelas tidak sepenuhnya seimbang, jumlah data pada masing-masing kelas masih cukup untuk digunakan dalam proses pelatihan dan pengujian model klasifikasi.

3.2 Explorasi Data Analysis (EDA)

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik dataset sebelum proses preprocessing dan pemodelan dilakukan. Analisis ini bertujuan untuk mengetahui distribusi label, karakteristik panjang komentar, pola penggunaan character obfuscation, serta keyword yang sering muncul pada komentar promosi judi online. Hasil EDA digunakan sebagai dasar dalam menentukan strategi preprocessing yang sesuai untuk menangani variasi teks pada komentar YouTube berbahasa Indonesia.

3.2.1 Analisis Panjang Komentar

Analisis panjang komentar dilakukan untuk mengetahui karakteristik dan sebaran panjang teks pada masing-masing kelas komentar dalam dataset.



Gambar 4 Panjang Komentar per Label

Berdasarkan Gambar 4, terlihat bahwa komentar promosi judi online (label 1) cenderung memiliki panjang komentar yang lebih besar dibandingkan komentar normal (label 0). Hal ini menunjukkan bahwa komentar judol umumnya mengandung lebih banyak unsur promosi, ajakan bermain, serta penyebutan nama situs tertentu. Selain itu, pada komentar judol juga ditemukan lebih banyak *outlier* dengan panjang komentar yang sangat tinggi. Kondisi ini menunjukkan adanya spam promosi dengan isi komentar yang panjang, repetitif, dan mengandung banyak variasi kata promosi untuk menarik perhatian pengguna.

3.2.2 Analisis Character Obfuscation

Analisis character obfuscation dilakukan untuk mengidentifikasi pola penyamaran teks yang digunakan pada komentar promosi judi online. Teknik penyamaran ini digunakan spammer agar komentar tidak mudah terdeteksi oleh sistem moderasi otomatis. Berdasarkan hasil analisis, ditemukan banyak komentar judol yang menggunakan Unicode stylized text, simbol dekoratif, serta angka sebagai pengganti karakter huruf tertentu.

Tabel 4. Hasil Analisis Character Obfuscation

Jenis Obfuscation	Jumlah
Unicode non-ascii	1875
Mengandung angka	1665

Hasil pada Tabel 4 menunjukkan bahwa sebanyak 1.875 komentar judol mengandung karakter Unicode non-ASCII, seperti huruf bergaya dekoratif atau stylized text. Selain itu, sebanyak 1.665 komentar mengandung angka yang digunakan sebagai bentuk character substitution atau leetspeak, misalnya penggunaan angka "8" pada nama situs tertentu. Temuan ini menunjukkan bahwa teknik obfuscation cukup dominan digunakan pada komentar promosi judi online sehingga diperlukan preprocessing tambahan berupa Unicode normalization dan character deobfuscation.

3.2.3 Analisis Spam Keyword

Selain visualisasi word cloud, dilakukan analisis terhadap beberapa spam keyword yang sering digunakan pada komentar promosi judi online.

Tabel 5. Frekuensi Spam Keyword

Spam Keyword	Frekuensi
alexis17	456
gacor	84
wd	59
maxwin	45
jp	34

Berdasarkan Tabel 5, keyword *alexis17* merupakan kata yang paling sering muncul dengan frekuensi 456 kali. Selain itu, ditemukan pula keyword lain seperti *gacor*, *wd*, *maxwin*, dan *weton88* yang umumnya digunakan dalam promosi situs judi online.

3.2.4 Analisis Word Cloud

Word cloud digunakan untuk memvisualisasikan kata-kata yang paling sering muncul pada masing-masing kategori komentar.

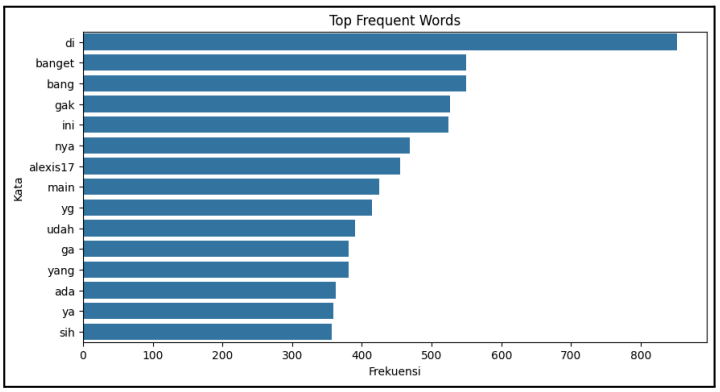


Gambar 5. Word Cloud Komentar

Berdasarkan Gambar 5, komentar normal didominasi oleh kata-kata yang berkaitan dengan isi video, tanggapan pengguna, dan interaksi antar penonton. Sedangkan komentar promosi judi online didominasi oleh nama situs tertentu serta kata-kata promosi seperti *gacor*, *maxwin*, *jp*, dan *wd* yang umum digunakan dalam promosi judi online.

3.2.5 Analisis Frekuensi Kata

Analisis frekuensi kata dilakukan untuk mengetahui kata-kata yang paling sering muncul pada dataset.

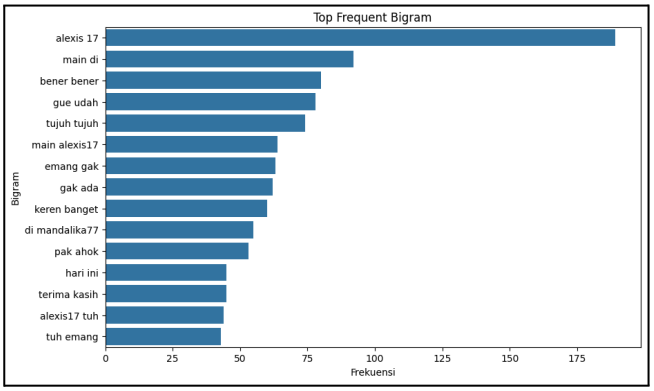


Gambar 6.Top 15 Kata Paling Sering Muncul

Berdasarkan Gambar 6, kata *alexis17* menjadi salah satu kata yang paling sering muncul pada dataset. Selain itu, terdapat kata umum seperti *banget*, *bang*, dan *main* yang banyak digunakan dalam komentar pengguna.

3.2.6 Analisis Bigram

Analisis bigram dilakukan untuk mengidentifikasi pasangan kata yang sering muncul secara berurutan pada dataset.



Gambar 7. Top 15 Bigram

Berdasarkan Tabel 7, pasangan kata *alexis 17* memiliki frekuensi tertinggi, diikuti oleh *main di* dan *main alexis17*. Hasil ini menunjukkan adanya pola promosi yang berulang pada komentar judi online.

3.2.7 Analisis Tren Waktu

Analisis tren waktu dilakukan untuk mengetahui pola kemunculan komentar promosi judi online berdasarkan dimensi waktu. Kolom tanggal pada dataset memiliki format yang tidak konsisten, sebagian berupa string ISO date dan sebagian lainnya berupa timestamp numerik dalam satuan detik, milidetik, maupun mikrodetik, sehingga diperlukan fungsi parsing khusus untuk mengonversi seluruh nilai ke format datetime yang seragam.

Analisis difokuskan pada data tahun 2025 yang memiliki jumlah data paling representatif. Berdasarkan visualisasi tren harian, komentar judol maupun normal tersebar sepanjang periode pengamatan dengan fluktuasi yang cukup tinggi. Pola ini mengindikasikan bahwa aktivitas spam komentar promosi judi online tidak bersifat musiman, melainkan berlangsung secara konsisten sepanjang waktu dengan intensitas yang bervariasi.

3.3 Hasil Preprocessing

3.3.1 Preprocessing Standard

Pada penelitian ini, skenario Standard Preprocessing digunakan sebagai tahapan dasar pembersihan teks sebelum dilakukan ekstraksi fitur menggunakan TF-IDF. Tujuan dari tahap ini adalah mengubah komentar mentah menjadi representasi teks yang lebih konsisten sehingga dapat diproses oleh model machine learning. Tahapan yang dilakukan meliputi lowercase, penghapusan URL, mention, hashtag, tanda baca, tokenisasi, stopword removal, dan stemming menggunakan library Sastrawi.

Melalui tahapan tersebut, berbagai unsur yang tidak relevan seperti emoji, simbol, URL, dan kata-kata umum yang kurang informatif berhasil dihilangkan. Selain itu, proses *stemming* membantu menyederhanakan kata berimbuhan menjadi bentuk kata dasar sehingga variasi kata yang memiliki makna sama dapat direpresentasikan secara lebih konsisten. Dengan demikian, data teks menjadi lebih bersih dan terstruktur sebelum digunakan pada tahap klasifikasi.

Tabel 6. Hasil Preprocessing Standard

Komentar Asli	Clean Standard
Makin yakin abis baca review lain tentang ✌ ✌ **SGI88**	abis baca review
Paling suka model H2 😍🔥	suka model h2
Mobilnya udah hancur 🥺	mobil udah hancur
MANUT88 benar2 bikin aku jadi sultan	88 benar2 bikin sultan
Semoga lekas sembuh mas Dipo	moga lekas recover mobil mas dipo

Berdasarkan Tabel 6, preprocessing standar berhasil menghilangkan berbagai noise seperti emoji, simbol, URL, dan kata-kata yang kurang informatif. Namun, beberapa keyword promosi

judi online yang ditulis menggunakan karakter Unicode stylized text atau bentuk penyamaran lainnya belum dapat dipertahankan secara optimal. Akibatnya, sebagian informasi penting yang berkaitan dengan promosi judi online berpotensi hilang selama proses preprocessing.

3.3.2 Preprocessing Advanced Normalization

Skenario *Advanced Preprocessing* dikembangkan untuk mengatasi berbagai bentuk *character obfuscation* yang banyak ditemukan pada komentar promosi judi online. Berbeda dengan *Standard Preprocessing*, skenario ini menambahkan beberapa proses normalisasi teks sebelum tokenisasi dan *stemming* dilakukan. Tahapan tambahan tersebut bertujuan untuk mengembalikan kata yang telah dimodifikasi menggunakan karakter Unicode, simbol dekoratif, angka, maupun variasi penulisan lainnya ke bentuk yang lebih mudah dikenali oleh model klasifikasi.

Penerapan normalisasi tambahan menjadi penting karena banyak komentar promosi judi online menggunakan teknik penyamaran karakter untuk menghindari deteksi otomatis. Jika tidak dilakukan normalisasi, kata yang sebenarnya memiliki makna sama dapat dianggap sebagai kata yang berbeda oleh model. Akibatnya, informasi penting yang berkaitan dengan promosi judi online tidak dapat dimanfaatkan secara optimal pada proses klasifikasi.

Tabel 7. Hasil Preprocessing Advanced

Komentar Asli	Hasil Clean Advanced
Makin yakin abis baca review lain tentang ✌ ✌ **SGI88**	abis baca review sgi88
▒***MANUT***88▒ benar2 bikin aku jadi sultan	manut88benar2 bikin sultan
gua udah ga bisa bayangin hidup tanpa ALEXIS-1…	gua udah ga bayangin hidup alexis17 sih

Berdasarkan Tabel 7, *Advanced Preprocessing* mampu mempertahankan berbagai keyword promosi judi online yang sebelumnya tersamarkan. Beberapa kata yang ditulis menggunakan Unicode *stylized text*, simbol dekoratif, maupun variasi karakter tertentu berhasil dinormalisasi menjadi bentuk yang lebih representatif. Hasil tersebut menunjukkan bahwa proses normalisasi tambahan mampu mengurangi dampak *character obfuscation* pada data komentar.

Selain menghasilkan teks yang lebih bersih, skenario ini juga mampu mempertahankan informasi yang berpotensi menjadi indikator penting dalam mendeteksi komentar promosi judi online. Dengan demikian, *Advanced Preprocessing* diharapkan dapat menghasilkan representasi fitur yang lebih baik dibandingkan *Standard Preprocessing*, sehingga berpotensi meningkatkan performa model klasifikasi pada tahap selanjutnya.

3.3.3 Preprocessing Dataset Clean

Pada skenario preprocessing dataset clean, penelitian menggunakan kolom komentar_clean yang telah tersedia pada dataset sebagai data dasar preprocessing. Kolom tersebut sebelumnya telah melalui proses cleaning sederhana sehingga beberapa noise seperti emoji, simbol tertentu, dan karakter yang tidak diperlukan sebagian besar telah dihilangkan. Oleh karena itu, preprocessing pada skenario ini dilakukan lebih ringan dibandingkan preprocessing standard maupun advanced normalization.

Tahapan preprocessing pada dataset clean meliputi proses lowercase untuk menyeragamkan huruf menjadi huruf kecil, penghapusan spasi berlebih, stopword removal menggunakan daftar stopword Bahasa Indonesia, serta stemming menggunakan library Sastrawi. Proses ini bertujuan untuk menyederhanakan bentuk kata sehingga representasi teks menjadi lebih konsisten sebelum dilakukan ekstraksi fitur menggunakan TF-IDF.

Berbeda dengan preprocessing advanced normalization, pada skenario ini tidak dilakukan Unicode normalization maupun character deobfuscation tambahan. Akibatnya, beberapa bentuk penyamaran karakter seperti Unicode stylized text, decorative symbol, maupun variasi penulisan tertentu masih belum sepenuhnya dapat dinormalisasi. Namun demikian, preprocessing dataset clean tetap mampu menghasilkan teks yang lebih bersih dan terstruktur dibandingkan data komentar mentah.

Tabel 8. Hasil Preprocessing Dataset Clean

Komentar Asli	Hasil Preprocessing Dataset Clean
Makin yakin abis baca review lain tentang ✌✌ **SGI88**	abis baca review
▒***MANUT***88▒ benar2 bikin aku jadi sultan	88 benar2 bikin sultan
bro alexis17 , ngadain giveaway nih	bro alexis17 ngadain giveaway nih
Busett cerahh banget 🚩**SGI88**🚩 encess sama koinya	busett cerahh banget encess koinya ngasih mulu
gue rela gak upgrade hp nabung alexis17	gue rela gak upgrade hp nabung alexis17

Berdasarkan Tabel 8, preprocessing dataset clean berhasil membersihkan sebagian besar noise pada komentar seperti emoji, simbol dekoratif, dan kata tidak penting. Namun, beberapa keyword promosi judi online yang ditulis menggunakan Unicode stylized text masih belum dapat dikenali dengan baik sehingga beberapa bentuk obfuscation belum berhasil dikembalikan ke bentuk normalnya. Hasil tersebut menunjukkan bahwa preprocessing dataset clean cukup efektif untuk membersihkan teks umum, tetapi masih memiliki keterbatasan dalam menangani character obfuscation yang kompleks. Oleh karena itu, penelitian ini juga menggunakan preprocessing advanced normalization untuk membantu mempertahankan keyword penting yang berkaitan dengan promosi judi online.

3.3.4 Perbandingan Hasil Preprocessing

Perbandingan dilakukan terhadap ketiga skenario preprocessing untuk melihat perbedaan hasil transformasi teks, khususnya dalam kemampuan mempertahankan keyword promosi judi online yang menggunakan character obfuscation.

Tabel 9. Hasil Perbandingan Preprocessing

Komentar Asli	Clean Standard	Clean Advanced	Clean Dataset
Makin yakin abis baca review lain	abis baca review	abis baca review sgi88	abis baca review

tentang ✌ ✌ **SGI88**			
MANUT88 benar2 bikin aku jadi sultan	88 benar2 bikin sultan	manut88benar2 bikin sultan	88 benar2 bikin sultan
pantes tongkrongan maen alexis17	pantes tongkrong maen alexis17	pantes tongkrong maen alexis17	pantes tongkrong maen alexis17
gua udah ga bisa bayangin hidup tanpa ALEXIS-1...	gua udah ga bayangin hidup alexis17 sih	gua udah ga bayangin hidup alexis17 sih	gua udah ga bayangin hidup alexis-17 sih

Berdasarkan tabel di atas, perbedaan antar skenario paling terlihat pada komentar yang mengandung unicode stylized text. Pada kasus "**SGI88**" dan "***MANUT***88", hanya preprocessing advanced yang berhasil mengembalikan keyword ke bentuk normalnya, sementara standard dan dataset clean kehilangan informasi tersebut. Untuk komentar yang tidak mengandung obfuscation, ketiga skenario menghasilkan output yang relatif sama. Hal ini menunjukkan bahwa perbedaan efek preprocessing hanya signifikan pada komentar judol yang menggunakan teknik penyamaran karakter, sedangkan pengaruhnya terhadap performa model klasifikasi akan dianalisis lebih lanjut pada tahap evaluasi.

3.4 Feature Extraction Menggunakan TF-IDF

Representasi teks diubah menjadi bentuk numerik menggunakan metode TF-IDF dengan konfigurasi unigram dan bigram serta pembatasan 10.000 fitur. Penggunaan bigram bertujuan untuk menangkap pasangan kata yang khas pada komentar judi online seperti "link alternatif" atau "daftar sekarang", sedangkan pembatasan fitur dilakukan untuk mengurangi kompleksitas dimensi data sekaligus mempertahankan fitur yang paling informatif.

Pemilihan metode TF-IDF didasarkan pada kemampuannya memberikan bobot lebih tinggi pada kata yang jarang muncul secara umum namun sering muncul pada dokumen tertentu. Dengan karakteristik ini, kata-kata khas komentar judi online seperti "gacor", "maxwin", dan nama situs tertentu akan mendapatkan representasi yang lebih signifikan dibandingkan kata umum yang tersebar merata di seluruh dokumen.

Proses TF-IDF diterapkan secara terpisah pada ketiga skenario preprocessing. Vectorizer hanya di-fit pada data training dan ditransformasikan pada data testing untuk menghindari data leakage, sehingga informasi dari data testing tidak bocor ke dalam proses pelatihan model. Hasil akhir berupa sparse matrix berukuran (n_sampel x 10.000) untuk masing-masing skenario yang selanjutnya siap digunakan sebagai input pelatihan model SVM dan MLP.

3.5 Hasil Persiapan Data Training dan Testing

Dataset dipisahkan menjadi variabel fitur (X) dan variabel target (y), di mana y diambil dari kolom label. Variabel X dibuat secara terpisah untuk masing-masing skenario, yaitu X_standard, X_advanced, dan X_dataset sesuai kolom hasil preprocessing masing-masing.

Pembagian data dilakukan dengan rasio 80:20 menggunakan stratified split untuk menjaga proporsi label pada data training dan testing tetap seimbang. Penggunaan stratified split menjadi penting mengingat dataset bersifat imbalanced, di mana komentar normal berjumlah 6.018 data dan komentar judol berjumlah 2.983 data. Tanpa stratifikasi, pembagian secara acak berisiko

menghasilkan subset data yang tidak merepresentasikan distribusi kelas asli sehingga dapat mempengaruhi performa model. Parameter random_state=42 juga digunakan untuk memastikan hasil pembagian dapat direproduksi secara konsisten. Berdasarkan total 9.001 data setelah cleaning, diperoleh 7.200 data training dan 1.801 data testing untuk masing-masing skenario.

Tabel 10. Hasil Pembagian Data Training dan Testing

Skenario	Data Training	Data Testing	Total
Standard	7.200	1.801	9.001
Advanced	7.200	1.801	9.001
Dataset Clean	7.200	1.801	9.001

3.6 Hasil Klasifikasi SVM

Pada Tahap ini dilakukan proses klasifikasi komentar YouTube menggunakan algoritma Support Vector Machine (SVM). Model dilatih menggunakan hasil feature extraction TF-IDF dari tiga skenario preprocessing, yaitu preprocessing standar, preprocessing advanced normalization, dan preprocessing dataset clean. Evaluasi performa model dilakukan menggunakan metrik accuracy, precision, recall, dan F1-score.

3.6.1 Hasil Klasifikasi SVM standar

Pada skenario preprocessing standard, model SVM digunakan untuk mengklasifikasikan komentar YouTube menjadi dua kategori, yaitu komentar normal (label 0) dan komentar promosi judi online (label 1). Evaluasi model dilakukan menggunakan metrik precision, recall, F1-score, dan accuracy.

Tabel 11. Hasil Evaluasi SVM Standard

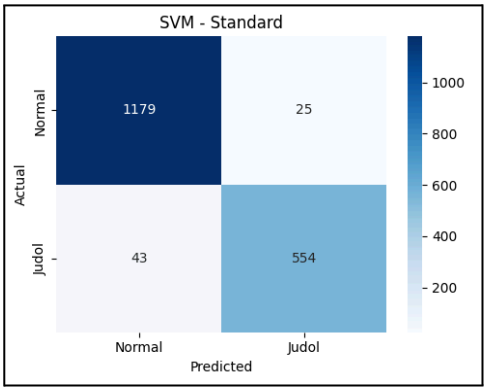
Kelas	Precisiom	Recall	F1-Score	Support
Normal (0)	0.96	0.98	0.97	1204
Judol (1)	0.96	0.93	0.94	597
Accuracy	-	-	0.96	1801

Berdasarkan Tabel 11, model SVM pada preprocessing standard menghasilkan accuracy sebesar 96%. Pada kelas komentar normal model memperoleh precision sebesar 0.96 dan recall sebesar 0.98, yang menunjukkan bahwa sebagian besar komentar normal berhasil dikenali dengan baik oleh model. Nilai F1-score sebesar 0.97 juga menunjukkan performa klasifikasi yang sangat baik pada kelas komentar normal.

Sementara itu, pada kelas komentar judol (label 1), model memperoleh precision sebesar 0,96 dengan recall sebesar 0,93. Hasil tersebut menunjukkan bahwa sebagian besar komentar promosi judi online berhasil dideteksi dengan baik, meskipun masih terdapat beberapa komentar judol yang salah diklasifikasikan sebagai komentar normal. Nilai F1-score sebesar 0,94 menunjukkan keseimbangan yang cukup baik antara precision dan recall pada proses klasifikasi komentar judol.

Selain evaluasi performa klasifikasi, dilakukan juga pengukuran runtime proses training dan pengujian model. Pada preprocessing standard, model SVM menghasilkan runtime sebesar 0.0309

detik. Hasil tersebut menunjukkan bahwa algoritma SVM mampu melakukan proses klasifikasi teks dengan cukup cepat pada dataset komentar YouTube berbahasa Indonesia.



Gambar 8. Confusion Matrix SVM Standard

Berdasarkan confusion matrix pada Gambar 8, model berhasil mengklasifikasikan 1179 komentar normal dan 554 komentar judol dengan benar. Namun, masih terdapat 25 komentar normal yang salah diprediksi sebagai komentar judol (false positive) serta 43 komentar judol yang salah diprediksi sebagai komentar normal (false negative).

Jumlah false negative yang masih muncul menunjukkan bahwa preprocessing standard belum sepenuhnya mampu menangani komentar judol yang menggunakan character obfuscation seperti Unicode stylized text maupun simbol dekoratif. Meskipun demikian, jumlah prediksi benar yang lebih dominan menunjukkan bahwa model SVM standard sudah memiliki performa klasifikasi yang cukup baik dalam mendeteksi komentar promosi judi online pada komentar YouTube berbahasa Indonesia.

3.6.2 Hasil Klasifikasi SVM Advanced Normalization

Pada skenario preprocessing advanced normalization, model Support Vector Machine (SVM) digunakan untuk mengklasifikasikan komentar YouTube menjadi dua kategori, yaitu komentar normal (label 0) dan komentar promosi judi online (label 1). Pada skenario ini, preprocessing dilakukan dengan tambahan normalisasi character obfuscation seperti unicode normalization, spaced-character merging, dan selective character deobfuscation untuk membantu model mengenali keyword promosi judi online yang sebelumnya tersamarkan.

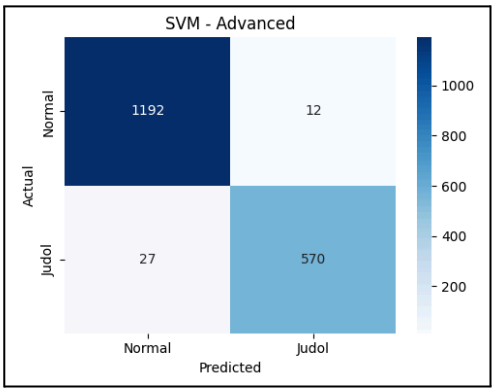
Tabel 12. Hasil Evaluasi SVM Advanced

Kelas	Precision	Recall	F1-Score	Support
Normal (0)	0.98	0.99	0.98	1204
Judol (1)	0.98	0.95	0.97	597
Accuracy	-	-	0.98	1801

Berdasarkan Tabel 12, model SVM pada preprocessing advanced normalization menghasilkan accuracy sebesar 98%, yang merupakan performa terbaik dibandingkan skenario preprocessing lainnya. Pada kelas komentar normal (label 0), model memperoleh precision sebesar 0,98 dan recall sebesar 0,99. Hasil tersebut menunjukkan bahwa hampir seluruh komentar normal berhasil dikenali dengan sangat baik oleh model. Nilai F1-score sebesar 0,98 juga menunjukkan keseimbangan performa klasifikasi yang sangat baik pada kelas komentar normal.

Sementara itu, pada kelas komentar judol (label 1), model memperoleh precision sebesar 0,98 dengan recall sebesar 0,95. Hasil tersebut menunjukkan bahwa sebagian besar komentar promosi judi online berhasil dideteksi dengan baik oleh model. Nilai F1-score sebesar 0,97 menunjukkan bahwa preprocessing advanced normalization mampu meningkatkan kemampuan model dalam mengenali pola komentar judol dibandingkan preprocessing standard.

Selain menghasilkan performa klasifikasi terbaik, preprocessing advanced normalization juga menghasilkan runtime tercepat dibandingkan preprocessing lainnya, yaitu sebesar 0.0235 detik. Hasil tersebut menunjukkan bahwa preprocessing advanced normalization membantu representasi fitur menjadi lebih konsisten sehingga proses training model menjadi lebih efisien.



Gambar 9. Hasil Evaluasi SVM Advanced

Berdasarkan confusion matrix pada Gambar 9, model berhasil mengklasifikasikan 1192 komentar normal dan 570 komentar judol dengan benar. Selain itu, hanya terdapat 12 komentar normal yang salah diprediksi sebagai komentar judol (false positive) dan 27 komentar judol yang salah diprediksi sebagai komentar normal (false negative).

Jumlah kesalahan klasifikasi yang lebih kecil dibandingkan preprocessing standard menunjukkan bahwa preprocessing advanced normalization berhasil membantu model dalam menangani komentar yang menggunakan character obfuscation seperti Unicode stylized text, simbol dekoratif, maupun variasi penulisan tertentu. Dengan demikian, kombinasi preprocessing advanced normalization dan algoritma SVM terbukti memberikan performa terbaik dalam mendeteksi komentar promosi judi online pada komentar YouTube berbahasa Indonesia.

3.6.3 Hasil Klasifikasi SVM Dataset Clean

Pada skenario preprocessing dataset clean, model Support Vector Machine (SVM) digunakan untuk mengklasifikasikan komentar YouTube menjadi dua kategori, yaitu komentar normal (label 0) dan komentar promosi judi online (label 1). Pada skenario ini, model menggunakan kolom komentar_clean yang sebelumnya telah melalui proses cleaning sederhana pada dataset.

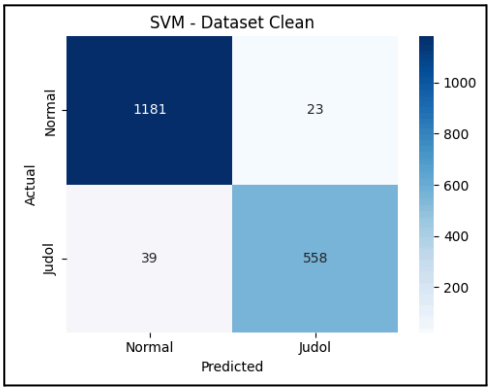
Tabel 13. Hasil Evaluasi SVM Dataset Clean

Kelas	Precision	Recall	F1-Score	Support
Normal (0)	0.97	0.98	0.97	1204
Judol (1)	0.96	0.93	0.95	597
Accuracy	-	-	0.97	1801

Berdasarkan Tabel 13, model SVM pada preprocessing dataset clean menghasilkan accuracy sebesar 97%. Pada kelas komentar normal (label 0), model memperoleh precision sebesar 0,97 dan recall sebesar 0,98. Hasil tersebut menunjukkan bahwa sebagian besar komentar normal berhasil dikenali dengan baik oleh model. Nilai F1-score sebesar 0,97 juga menunjukkan performa klasifikasi yang sangat baik pada kelas komentar normal.

Sementara itu, pada kelas komentar judol (label 1), model memperoleh precision sebesar 0,96 dengan recall sebesar 0,93. Hasil tersebut menunjukkan bahwa sebagian besar komentar promosi judi online berhasil dideteksi oleh model, meskipun masih terdapat beberapa komentar judol yang salah diprediksi sebagai komentar normal. Nilai F1-score sebesar 0,95 menunjukkan keseimbangan yang cukup baik antara precision dan recall pada proses klasifikasi komentar judol.

Pada preprocessing dataset clean, model SVM menghasilkan runtime sebesar 0.0237 detik. Runtime tersebut masih tergolong cepat dan menunjukkan bahwa algoritma SVM mampu menangani proses klasifikasi komentar secara efisien pada seluruh skenario preprocessing.



Gambar 10. Confusion Matrix SVM Dataset Clean

Berdasarkan confusion matrix pada Gambar 10, model berhasil mengklasifikasikan 1181 komentar normal dan 558 komentar judol dengan benar. Namun, masih terdapat 23 komentar normal yang salah diprediksi sebagai komentar judol (false positive) serta 39 komentar judol yang salah diprediksi sebagai komentar normal (false negative).

Hasil tersebut menunjukkan bahwa preprocessing dataset clean mampu menghasilkan performa klasifikasi yang cukup baik karena data komentar telah melalui proses cleaning sebelumnya. Akan tetapi, performa model masih sedikit lebih rendah dibandingkan preprocessing advanced normalization karena beberapa bentuk character obfuscation seperti Unicode stylized text dan variasi penulisan tertentu belum sepenuhnya berhasil dinormalisasi. Meskipun demikian, kombinasi preprocessing dataset clean dan algoritma SVM tetap menunjukkan kemampuan klasifikasi yang baik dalam mendeteksi komentar promosi judi online pada komentar YouTube berbahasa Indonesia.

3.7 Hasil Klasifikasi MLP

Pada tahap ini dilakukan proses klasifikasi komentar YouTube menggunakan algoritma Multilayer Perceptron (MLP). Model dilatih menggunakan hasil feature extraction TF-IDF dari tiga skenario preprocessing, yaitu preprocessing standar, preprocessing advanced normalization, dan preprocessing dataset clean. Arsitektur MLP yang digunakan terdiri atas dua hidden layer dengan 128 dan 64 neuron, menggunakan fungsi aktivasi ReLU serta optimizer Adam dengan max_iter = 300.

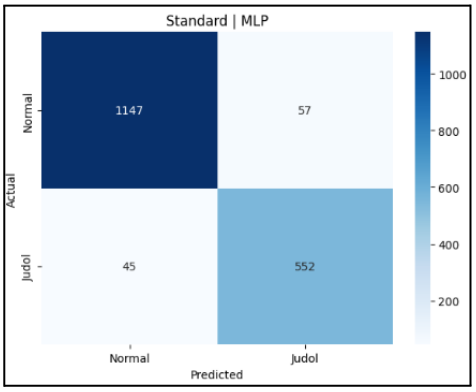
3.7.1 Hasil Klasifikasi MLP Standard

Pada skenario preprocessing standard, model MLP digunakan untuk mengklasifikasikan komentar YouTube menjadi dua kategori, yaitu komentar normal (label 0) dan komentar promosi judi online (label 1).

Tabel 14. Hasil Evaluasi MLP Standard

Kelas	Precision	Recall	F1-Score	Support
Normal (0)	0.96	0.95	0.96	1204
Judol (1)	0.91	0.92	0.92	597
Accuracy	-	-	0.94	1801

Berdasarkan tabel di atas, model MLP pada preprocessing standard menghasilkan accuracy sebesar 94%. Pada kelas komentar normal, model memperoleh precision sebesar 0.96 dan recall sebesar 0.95, menunjukkan bahwa sebagian besar komentar normal berhasil dikenali dengan baik. Sementara itu, pada kelas komentar judol, model memperoleh precision sebesar 0.91 dengan recall sebesar 0.92. Masih terdapat beberapa komentar judol yang tidak berhasil dideteksi, terutama pada komentar yang menggunakan character obfuscation seperti Unicode stylized text maupun simbol dekoratif yang tidak dapat ditangani oleh preprocessing standard.



Gambar 11. Confusion Matrix MLP Standard

Berdasarkan confusion matrix, model MLP Standard mengklasifikasikan 1.147 komentar normal dan 552 komentar judol dengan benar, dengan 57 false positive dan 45 false negative. Runtime model MLP Standard adalah 70.109 detik.

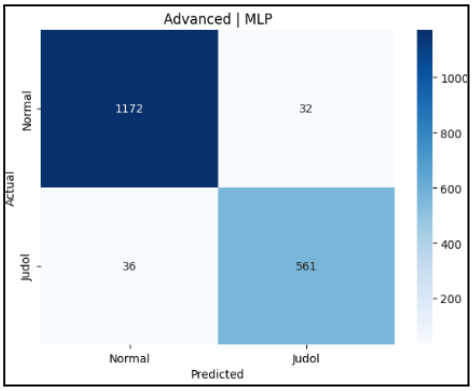
3.7.2 Hasil Klasifikasi MLP Advanced

Pada skenario preprocessing advanced normalization, model MLP digunakan dengan tambahan normalisasi character obfuscation untuk membantu model mengenali keyword promosi judi online yang sebelumnya tersamarkan.

Tabel 15. Hasil Evaluasi MLP Advanced

Kelas	Precision	Recall	F1-Score	Support
Normal (0)	0.97	0.97	0.97	1204
Judol (1)	0.95	0.94	0.94	597
Accuracy	-	-	0.96	1801

Model MLP pada preprocessing advanced normalization menghasilkan accuracy sebesar 96%, meningkat dibandingkan skenario standard. Pada kelas komentar normal, model memperoleh precision dan recall sebesar 0.97, sedangkan pada kelas komentar judol diperoleh precision sebesar 0.95 dan recall sebesar 0.94. Peningkatan performa ini menunjukkan bahwa normalisasi character obfuscation berhasil membantu model dalam mengenali keyword promosi judi online yang sebelumnya tersamarkan.



Gambar 12. Confusion Matrix MLP Advanced

Berdasarkan confusion matrix, model MLP Advanced mengklasifikasikan 1.172 komentar normal dan 561 komentar judol dengan benar, dengan hanya 32 false positive dan 36 false negative. Runtime model MLP Advanced adalah 72.332 detik.

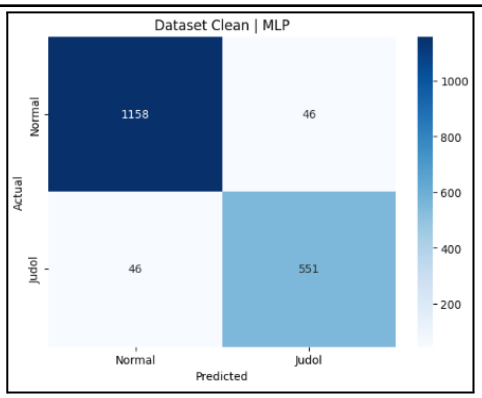
3.7.3 Hasil Klasifikasi Dataset Clean

Pada skenario preprocessing dataset clean, model MLP menggunakan kolom komentar_clean yang telah tersedia pada dataset sebagai data dasar preprocessing.

Tabel 16. Hasil Evaluasi MLP Dataset Clean

Kelas	Precision	Recall	F1-Score	Support
Normal (0)	0.96	0.96	0.96	1204
Judol (1)	0.92	0.92	0.92	597
Accuracy	-	-	0.95	1801

Model MLP pada preprocessing dataset clean menghasilkan accuracy sebesar 95%. Pada kelas komentar normal, model memperoleh precision dan recall sebesar 0.96, sedangkan pada kelas komentar judol diperoleh precision dan recall sebesar 0.92. Performa model pada skenario ini berada di antara Standard dan Advanced Preprocessing, menunjukkan bahwa data yang telah melalui proses cleaning sederhana pada dataset mampu menghasilkan representasi teks yang cukup baik meskipun belum optimal dalam menangani character obfuscation yang kompleks.



Gambar 13. Confusion Matrix MLP Dataset Clean

Berdasarkan confusion matrix, model MLP Dataset Clean mengklasifikasikan 1.158 komentar normal dan 551 komentar judol dengan benar, dengan 46 false positive dan 46 false negative. Runtime model MLP Dataset Clean adalah 71.009 detik.

3.8 Hasil Cross Validation

Selain menggunakan data uji untuk mengevaluasi performa model, penelitian ini juga menerapkan metode cross validation untuk mengukur kestabilan dan kemampuan generalisasi model. Cross validation dilakukan menggunakan skema 5-fold cross validation pada seluruh kombinasi model dan skenario preprocessing. Metrik evaluasi yang digunakan adalah F1-score karena mampu memberikan gambaran yang seimbang antara precision dan recall dalam mendeteksi komentar promosi judi online.

3.8.1 Hasil Cross Validation

Hasil pengujian menggunakan metode 5-fold cross validation pada model SVM dan MLP untuk setiap skenario preprocessing ditunjukkan pada Tabel 3.16. Nilai yang ditampilkan merupakan F1-score pada masing-masing fold beserta rata-rata F1-score yang diperoleh dari seluruh fold pengujian.

Tabel 17. Hasil 5-Fold Cross Validation

Model	Dataset	Fold-1	Fold-2	Fold-3	Fold-4	Fold-5	Mean F1
SVM	Standard	0.9296	0.9386	0.9359	0.9248	0.9451	0.9348
SVM	Advanced	0.9582	0.9591	0.9503	0.9603	0.9646	0.9585
SVM	Dataset Clean	0.9294	0.9453	0.9378	0.9263	0.9418	0.9361
MLP	Standard	0.9244	0.9326	0.9182	0.9089	0.9356	0.9239
MLP	Advanced	0.9505	0.9487	0.9448	0.9443	0.9510	0.9479
MLP	Dataset Clean	0.9239	0.9371	0.9219	0.9172	0.9221	0.9244

Cross validation dilakukan menggunakan metode 5-fold cross validation untuk mengukur kestabilan performa model pada data pelatihan. Pengujian dilakukan pada seluruh kombinasi model dan skenario preprocessing, yaitu SVM dan MLP dengan Standard Preprocessing, Advanced Preprocessing, serta Dataset Clean Preprocessing. Metrik yang digunakan adalah

F1-score karena mampu memberikan keseimbangan antara precision dan recall pada permasalahan klasifikasi komentar promosi judi online.

Berdasarkan hasil pengujian, model SVM dengan Advanced Preprocessing memperoleh nilai rata-rata F1-score tertinggi sebesar 0,9585, diikuti oleh MLP dengan Advanced Preprocessing sebesar 0,9479. Sementara itu, pada skenario Standard Preprocessing dan Dataset Clean Preprocessing, nilai rata-rata F1-score yang diperoleh cenderung lebih rendah. Hasil tersebut menunjukkan bahwa penerapan Advanced Preprocessing mampu meningkatkan kualitas fitur yang dihasilkan sehingga membantu model dalam membedakan komentar normal dan komentar yang mengandung promosi judi online secara lebih konsisten.

3.8.2 Analisis Kestabilan Model

Selain memperoleh nilai rata-rata F1-score yang tinggi, model SVM dan MLP pada skenario Advanced Preprocessing juga menunjukkan performa yang relatif stabil pada setiap fold pengujian. Hal ini dapat dilihat dari perbedaan nilai F1-score antar fold yang tidak terlalu besar, sehingga mengindikasikan bahwa model memiliki kemampuan generalisasi yang baik dan tidak terlalu bergantung pada pembagian data tertentu.

Dibandingkan dengan MLP, model SVM menunjukkan performa yang lebih baik pada seluruh skenario preprocessing. Nilai rata-rata F1-score SVM selalu lebih tinggi dibandingkan MLP, baik pada Standard Preprocessing, Advanced Preprocessing, maupun Dataset Clean Preprocessing. Selain itu, SVM dengan Advanced Preprocessing menjadi kombinasi yang paling konsisten dengan rata-rata F1-score sebesar 0,9585. Hasil ini menunjukkan bahwa pendekatan normalisasi tambahan pada Advanced Preprocessing berhasil membantu model dalam mengenali berbagai bentuk obfuscation yang umum digunakan pada komentar promosi judi online.

3.9 Hasil Feature Importance

Analisis feature importance dilakukan untuk mengetahui kata-kata yang paling berpengaruh dalam proses klasifikasi komentar promosi judi online pada kedua model, yaitu SVM dan MLP. Analisis ini bertujuan untuk memahami pola kata yang digunakan model dalam membedakan komentar normal dan komentar judol, sehingga dapat memberikan insight mengenai karakteristik teks yang paling informatif dalam proses deteksi.

3.9.1 Feature Importance SVM

Pada model SVM, feature importance diperoleh dari nilai koefisien (coef_) pada LinearSVC yang merepresentasikan bobot setiap fitur dalam proses klasifikasi. Nilai koefisien positif menunjukkan kontribusi fitur terhadap kelas judol, sedangkan nilai koefisien negatif menunjukkan kontribusi fitur terhadap kelas normal.

Tabel 18. Hasil Feature Importance SVM Judol

Feature	Coef (Judol)
alexis17	7.663144
mandalika77	4.832686
pulauwin	4.060575
sgi88	3.771373

rezeki	3.404107
weton88	3.023941
berkah99	2.719165
pluto88	2.595348
jepe	2.451504
pulau777	2.347898
manut88	2.062613
wede	2.056730
agustoto	2.034786
koislot	2.025437
gacir	1.991337

Tabel 19. Hasil Feature Importance SVM Normal

Feature	Coef (Normal)
mulyono	-0.982801
presiden	-0.935567
dislike	-0.862785
mas	-0.845663
beli	-0.830283
gd	-0.825267
kalah	-0.791166
gila hasil	-0.784819
ahok	-0.774994
mobil	-0.768786

Berdasarkan hasil analisis, kata "alexis17" menjadi fitur paling dominan dengan koefisien tertinggi sebesar 7.663, diikuti "mandalika77" (4.832), "pulauwin" (4.060), dan "sgi88" (3.771). Kata-kata tersebut merupakan nama situs judi online yang umum digunakan di Indonesia. Sementara itu, fitur yang paling kuat mengidentifikasi komentar normal didominasi oleh kata-kata yang berkaitan dengan topik politik dan kehidupan sehari-hari seperti "mulyono", "presiden", "dislike", dan "mobil". Temuan ini menunjukkan bahwa model SVM berhasil mempelajari pola kata yang benar-benar mencerminkan karakteristik komentar promosi judi online.

3.9.2 Feature Importance MLP

Pada model MLP, feature importance diperoleh dari rata-rata bobot layer pertama (coefs_[0].mean(axis=1)) yang merepresentasikan kontribusi rata-rata setiap fitur terhadap seluruh neuron pada hidden layer pertama.

Tabel 20. Hasil Feature Importance MLP Judol

Feature	Weight (Judol)
ga	0.036594
tuh	0.034250
bang	0.033071
aja	0.032115
gak	0.031433
ya	0.029424
nya	0.028379
facebluesmiling	0.027770
langsung	0.027721
nih	0.027349

Tabel 21. Hasil Feature Importance MLP Normal

Feature	Weight (Normal)
auto	-0.026380
menang	-0.024685
alexis17	-0.019933
berkah99	-0.018668
tiada	-0.017385
geeecess	-0.017086
mandalika77	-0.016682
pulauwin	-0.015993
manut88	-0.015781
old	-0.015643

Berbeda dengan SVM, feature importance pada MLP menunjukkan pola yang berbeda. Kata-kata umum seperti "ga", "tuh", "bang", dan "aja" justru mendominasi fitur untuk kelas judol, sedangkan nama situs seperti "alexis17" dan "mandalika77" justru muncul dengan bobot negatif. Hal ini disebabkan oleh cara kerja MLP yang mempelajari kombinasi fitur secara non-linear melalui beberapa lapisan, sehingga representasi feature importance-nya tidak sesederhana dan

seintuitif SVM. Perbedaan karakteristik feature importance antara SVM dan MLP ini menjadi salah satu faktor yang menjelaskan mengapa SVM menghasilkan performa klasifikasi yang lebih baik dan lebih mudah diinterpretasikan pada kasus deteksi komentar promosi judi online berbahasa Indonesia.

3.10 Error Analysis

Pada tahap error analysis dilakukan analisis terhadap komentar yang mengalami kesalahan klasifikasi pada model SVM dan MLP. Analisis ini bertujuan untuk mengetahui faktor penyebab model masih menghasilkan false positive maupun false negative pada beberapa komentar.

3.10.1 Error Analysis SVM

Untuk melihat performa model secara lebih mendalam, dilakukan analisis terhadap jumlah kesalahan prediksi pada setiap skenario preprocessing menggunakan algoritma SVM.

Tabel 22. Jumlah Kesalahan Prediksi SVM

Skenario Preprocessing	Jumlah Salah Prediksi
Standard	68
Advanced	39
Dataset Clean	62

Berdasarkan Tabel 22, preprocessing advanced normalization menghasilkan jumlah kesalahan prediksi paling sedikit dibandingkan preprocessing standard maupun preprocessing dataset clean. Hasil tersebut menunjukkan bahwa preprocessing advanced normalization mampu membantu model SVM mengenali komentar promosi judi online dengan lebih baik, terutama pada komentar promosi judi online dengan lebih baik, terutama pada komentar yang menggunakan character obfuscation.

Tabel 23. Contoh Kesalahan Prediksi SVM

Komentar	Actual	Predicted
moga amal ibadah terima sisi tuhan	1	0
tetangga gw sore main p u l a u w i n	1	0
kmrn iseng hands on x6 aja udah asa sultan gimana	0	1
hadir tonton setiamanut88	1	0
gue pergi aja nyebut pulauwin	0	1

Berdasarkan hasil analisis, beberapa komentar judol masih diprediksi sebagai komentar normal karena menggunakan pola character obfuscation seperti pemisahan karakter, penggunaan keyword tersamarkan, maupun kalimat promosi yang tidak secara langsung mengandung keyword spam yang kuat. Selain itu, beberapa komentar normal diprediksi sebagai komentar judol karena mengandung kata seperti “sultan” atau “pulauwin” yang sering muncul pada komentar promosi judi online sehingga dianggap sebagai indikator spam oleh model.

3.10.2 Error Analysis MLP

Selain model SVM, dilakukan juga analisis kesalahan klasifikasi pada model Multilayer Perceptron (MLP) untuk melihat perbedaan performa antar model pada setiap skenario preprocessing.

Tabel 24. Jumlah Kesalahan Prediksi MLP

Skenario	Jumlah Salah Prediksi
Standard	102
Advanced	68
Dataset Clean	92

Berdasarkan Tabel 24, preprocessing advanced normalization juga menghasilkan jumlah kesalahan prediksi paling sedikit pada model MLP dibandingkan preprocessing standard maupun preprocessing dataset clean. Namun, jumlah error pada model MLP masih lebih tinggi dibandingkan model SVM pada seluruh skenario preprocessing.

Tabel 25. Contoh Kesalahan Prediksi MLP

Komentar	Actual	Predicted
moga amal ibadah terima sisi tuhan	1	0
tetangga gw sore main p u l a u w i n	1	0
gila ya alexis17 mana ashu percaya kagak nih	1	0
kmrn iseng hands on x6 aja udah asa sultan gimana	0	1
aantoniomy9xs terimakasih info coba daftar	0	1

Berdasarkan hasil analisis, model MLP masih mengalami kesulitan dalam membedakan komentar normal dan komentar judol pada komentar yang memiliki variasi konteks kata maupun bentuk obfuscation kompleks. Selain itu, beberapa komentar normal yang mengandung kata seperti “alexis17”, “sultan”, atau “daftar” juga sering diprediksi sebagai komentar judol karena memiliki kemiripan pola dengan komentar spam promosi judi online.

3.10.3 Analisis Kesalahan Model

Secara umum, sebagian besar *false negative* terjadi pada komentar yang menggunakan *character obfuscation* kompleks, pemisahan karakter, serta penggunaan keyword yang telah dimodifikasi sehingga pola promosi judi online menjadi lebih sulit dikenali oleh model. Sementara itu, *false positive* umumnya ditemukan pada komentar normal yang mengandung kata atau nama situs yang sering muncul pada komentar judol, seperti *sultan*, *alexis17*, dan *pulauwin*, sehingga model menganggap komentar tersebut sebagai komentar promosi judi online. Selain itu, beberapa komentar judol tidak mengandung keyword spam yang kuat sehingga meningkatkan kemungkinan terjadinya kesalahan klasifikasi.

Meskipun demikian, preprocessing advanced normalization terbukti mampu mengurangi jumlah kesalahan klasifikasi pada kedua model dibandingkan preprocessing standard maupun preprocessing dataset clean. Hasil tersebut menunjukkan bahwa normalisasi character obfuscation

memiliki pengaruh penting dalam meningkatkan performa sistem deteksi komentar promosi judi online pada komentar YouTube berbahasa Indonesia.

3.11 Evaluasi dan Perbandingan Model

Setelah dilakukan proses klasifikasi menggunakan algoritma SVM dan MLP pada tiga skenario preprocessing, tahap selanjutnya adalah melakukan evaluasi dan perbandingan performa model. Perbandingan dilakukan berdasarkan nilai accuracy, precision, recall, dan F1-score, serta mempertimbangkan hasil cross validation, confusion matrix, dan waktu komputasi (runtime). Analisis ini bertujuan untuk mengetahui pengaruh skenario preprocessing terhadap performa model sekaligus menentukan model yang paling efektif dalam mendeteksi komentar promosi judi online pada platform YouTube.

3.11.1 Perbandingan Performa Model

Perbandingan performa model dilakukan menggunakan metrik accuracy, precision, recall, dan F1-score. Hasil evaluasi untuk setiap kombinasi model dan skenario preprocessing ditunjukkan pada Tabel 3.25.

Tabel 26. Perbandingan Kinerja Model

Skenario	Model	Accuracy	Precision	Recall	F1-Score
Standard	SVM	0.9622	0.9568	0.9280	0.9422
Standard	MLP	0.9434	0.9064	0.9246	0.9154
Advanced	SVM	0.9783	0.9794	0.9548	0.9669
Advanced	MLP	0.9622	0.9460	0.9397	0.9429
Dataset Clean	SVM	0.9656	0.9604	0.9347	0.9474
Dataset Clean	MLP	0.9489	0.9229	0.9229	0.9229

Berdasarkan Tabel 26, model SVM dengan Advanced Preprocessing memperoleh performa terbaik dengan accuracy sebesar 97,83%, precision sebesar 97,94%, recall sebesar 95,48%, dan F1-score sebesar 96,69%. Sementara itu, performa terbaik pada algoritma MLP juga diperoleh pada skenario Advanced Preprocessing dengan F1-score sebesar 94,29%. Secara umum, SVM menghasilkan performa yang lebih tinggi dibandingkan MLP pada seluruh skenario preprocessing, serta menunjukkan bahwa Advanced Preprocessing mampu meningkatkan kinerja kedua model dalam mendeteksi komentar promosi judi online.

3.11.2 Perbandingan Runtime

Selain performa klasifikasi, penelitian ini juga membandingkan waktu komputasi yang dibutuhkan oleh masing-masing model selama proses pelatihan dan prediksi. Hasil pengukuran runtime ditunjukkan pada Tabel 3.25.

Tabel 27. Perbandingan Runtime

Model	Runtime (Detik)
SVM Standard	0.030981

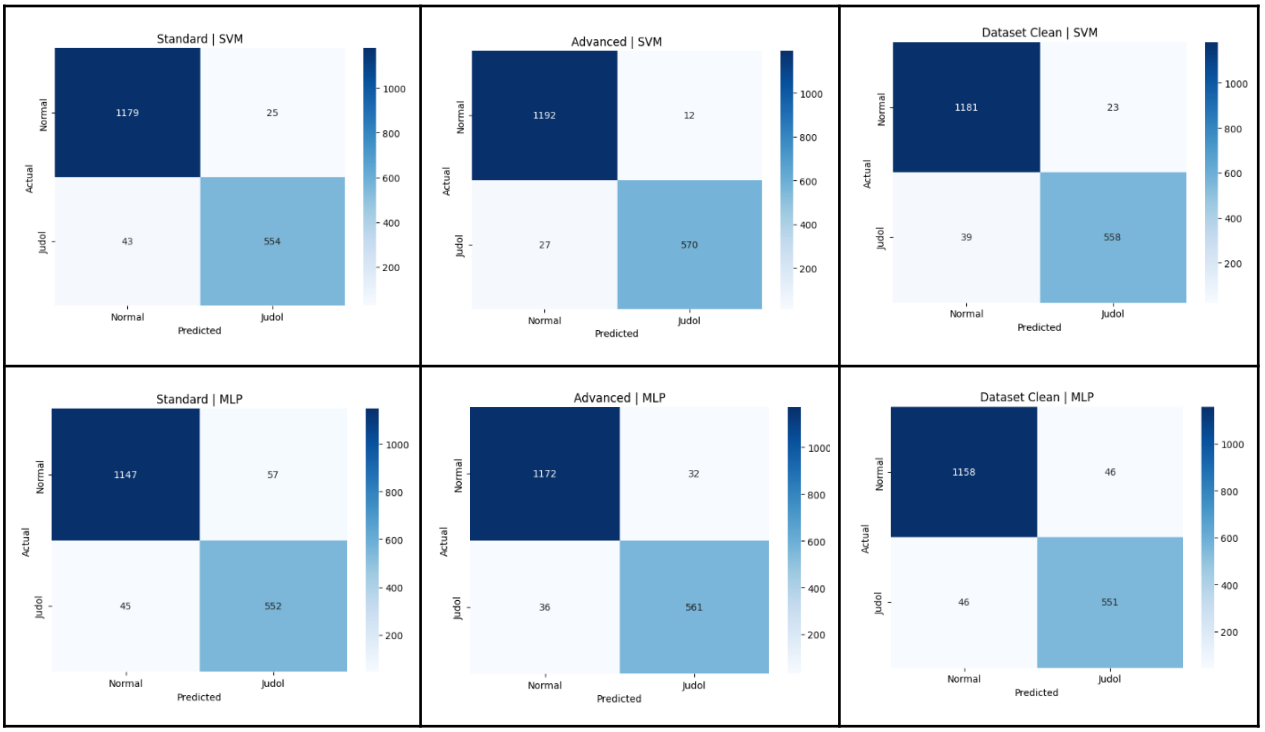
SVM Advanced	0.023540
SVM Dataset Clean	0.023727
MLP Standard	70.109012
MLP Advanced	72.331725
MLP Dataset Clean	71.009437

Berdasarkan Tabel 27, algoritma SVM memiliki waktu komputasi yang jauh lebih cepat dibandingkan MLP. Seluruh skenario SVM hanya membutuhkan waktu sekitar 0,02–0,03 detik, sedangkan MLP membutuhkan waktu sekitar 70–72 detik. Perbedaan ini menunjukkan bahwa SVM lebih efisien dalam memproses data teks berbasis TF-IDF dengan jumlah fitur yang tinggi.

Pada algoritma MLP, proses pelatihan membutuhkan waktu yang lebih lama karena model harus melakukan optimasi bobot pada beberapa lapisan jaringan saraf melalui proses iteratif. Sebaliknya, SVM mampu menemukan hyperplane optimal dengan proses komputasi yang lebih sederhana sehingga menghasilkan runtime yang jauh lebih rendah.

3.11.3 Perbandingan Confusion Matrix

Confusion matrix digunakan untuk menganalisis kemampuan model dalam mengklasifikasikan komentar normal dan komentar promosi judi online secara lebih rinci.Gambar 3.X menunjukkan confusion matrix untuk seluruh kombinasi model dan skenario preprocessing.



Gambar 14. Confusion Matrix Semua Skenario

Berdasarkan confusion matrix, skenario Standard Preprocessing model SVM berhasil mengklasifikasikan sebanyak 1.173 komentar normal dan 554 komentar promosi judi online dengan benar, sedangkan jumlah kesalahan klasifikasi terdiri dari 31 false positive dan 43 false negative. Sementara itu, model MLP menghasilkan jumlah kesalahan yang lebih tinggi, yaitu 56 false positive dan 45 false negative, sehingga performanya berada di bawah SVM pada skenario yang sama.

Pada skenario Advanced Preprocessing, kedua model mengalami peningkatan performa. Model SVM menghasilkan 1.192 true negative dan 570 true positive, dengan hanya 12 false positive dan 27 false negative. Sementara itu, model MLP menghasilkan 1.172 true negative dan 561 true positive, dengan 32 false positive dan 36 false negative. Hasil ini menunjukkan bahwa Advanced Preprocessing mampu mengurangi jumlah kesalahan klasifikasi pada kedua algoritma.

Pada skenario Dataset Clean Preprocessing, model SVM kembali menunjukkan performa yang lebih baik dibandingkan MLP dengan jumlah kesalahan klasifikasi yang lebih rendah. Secara keseluruhan, kombinasi SVM dan Advanced Preprocessing menghasilkan confusion matrix terbaik karena memiliki jumlah prediksi benar tertinggi serta jumlah false positive dan false negative terendah. Temuan ini sejalan dengan hasil evaluasi menggunakan accuracy, precision, recall, dan F1-score yang menunjukkan bahwa SVM dengan Advanced Preprocessing merupakan model terbaik pada penelitian ini.

3.11.4 Pengaruh Preprocessing terhadap Performa Model

Hasil penelitian menunjukkan bahwa skenario preprocessing memberikan pengaruh terhadap performa model klasifikasi. Pada kedua algoritma, Advanced Preprocessing menghasilkan nilai accuracy, precision, recall, dan F1-score yang lebih tinggi dibandingkan Standard Preprocessing maupun Dataset Clean Preprocessing. Hasil ini menunjukkan bahwa proses preprocessing yang lebih komprehensif mampu meningkatkan kualitas representasi fitur yang digunakan dalam proses klasifikasi.

Pada algoritma SVM, nilai F1-score meningkat dari 94,22% pada Standard Preprocessing menjadi 96,69% pada Advanced Preprocessing. Peningkatan serupa juga terlihat pada algoritma MLP, di mana nilai F1-score meningkat dari 91,54% menjadi 94,29%. Sementara itu, skenario Dataset Clean Preprocessing menghasilkan performa yang lebih baik dibandingkan Standard Preprocessing, namun masih berada di bawah Advanced Preprocessing.

Peningkatan performa tersebut terjadi karena Advanced Preprocessing menerapkan proses normalisasi tambahan, seperti normalisasi karakter Unicode, penggabungan karakter yang dipisahkan spasi, normalisasi leetspeak, dan penggantian simbol tertentu. Proses tersebut mampu mengurangi variasi penulisan kata yang sengaja dimodifikasi (obfuscation) pada komentar promosi judi online sehingga kata-kata yang memiliki makna sama dapat direpresentasikan dalam bentuk yang lebih konsisten. Dengan representasi teks yang lebih seragam, model dapat mengenali pola komentar promosi judi online dengan lebih akurat dan menghasilkan performa klasifikasi yang lebih baik.

3.12 Pemilihan Model Terbaik

Pemilihan model terbaik dilakukan berdasarkan hasil evaluasi yang meliputi accuracy, precision, recall, F1-score, cross validation, confusion matrix, dan runtime pada seluruh kombinasi model dan skenario preprocessing. Berdasarkan hasil tersebut, model SVM dengan Advanced Preprocessing dipilih sebagai model terbaik dalam penelitian ini karena menghasilkan performa klasifikasi yang paling tinggi dibandingkan model lainnya.

Model SVM dengan Advanced Preprocessing memperoleh accuracy sebesar 97,83%, precision sebesar 97,94%, recall sebesar 95,48%, dan F1-score sebesar 96,69%. Selain itu, model ini juga menunjukkan performa yang stabil pada proses cross validation dengan rata-rata F1-score

sebesar 95,85%, serta menghasilkan jumlah false positive dan false negative yang lebih rendah dibandingkan kombinasi model lainnya.

Dari sisi efisiensi komputasi, SVM juga memiliki runtime yang jauh lebih cepat dibandingkan MLP. Runtime SVM berada pada kisaran 0,02–0,03 detik, sedangkan MLP memerlukan waktu sekitar 70–72 detik. Dengan mempertimbangkan performa klasifikasi, kestabilan model, dan efisiensi komputasi, kombinasi SVM dan Advanced Preprocessing dipilih sebagai model terbaik untuk mendeteksi komentar promosi judi online pada platform YouTube.

3.13 Interpretasi dan Insight

Berdasarkan hasil penelitian, komentar promosi judi online pada platform YouTube memiliki karakteristik khusus seperti penggunaan kata promosi, nama situs tertentu, serta istilah khas seperti “gacor”, “maxwin”, dan “wd”. Selain itu, banyak komentar menggunakan teknik *character obfuscation* seperti Unicode stylized text, simbol dekoratif, dan pemisahan karakter untuk menyamarkan keyword promosi judi online agar tidak mudah terdeteksi oleh sistem moderasi otomatis. Hasil eksperimen menunjukkan bahwa preprocessing memiliki pengaruh yang signifikan terhadap performa model klasifikasi, di mana *advanced preprocessing* mampu mengenali pola komentar dengan lebih baik karena berhasil melakukan normalisasi terhadap berbagai bentuk obfuscation.

Berdasarkan hasil evaluasi, kombinasi SVM dan *Advanced Preprocessing* menghasilkan performa terbaik dengan accuracy sebesar 97,83% dan F1-score sebesar 96,69%, serta jumlah kesalahan prediksi yang lebih rendah dibandingkan model lainnya. Secara umum, penelitian ini menunjukkan bahwa pendekatan berbasis *Natural Language Processing* (NLP) dan *machine learning* memiliki potensi yang baik untuk diterapkan pada sistem moderasi komentar otomatis di media sosial guna membantu mendeteksi dan mengurangi penyebaran komentar promosi judi online secara lebih cepat dan efisien.

4. Kesimpulan dan Saran

4.1 Kesimpulan

Berdasarkan hasil penelitian, algoritma *Support Vector Machine* (SVM) dan *Multilayer Perceptron* (MLP) mampu digunakan untuk mendeteksi komentar promosi judi online pada platform YouTube berbahasa Indonesia dengan performa yang baik. Hasil pengujian menunjukkan bahwa skenario *Advanced Preprocessing* menghasilkan performa yang lebih tinggi dibandingkan *Standard Preprocessing* maupun *Dataset Clean Preprocessing*. Penerapan normalisasi tambahan seperti *Unicode normalization*, *spaced-character merging*, *leetspeak normalization*, dan *symbol replacement* terbukti mampu membantu model mengenali berbagai bentuk *character obfuscation* yang sering digunakan pada komentar promosi judi online.

Berdasarkan seluruh hasil evaluasi, kombinasi SVM dengan *Advanced Preprocessing* merupakan model terbaik dengan nilai *accuracy* sebesar 97,83%, *precision* sebesar 97,94%, *recall* sebesar 95,48%, dan *F1-score* sebesar 96,69%. Model ini juga memperoleh rata-rata *cross validation F1-score* tertinggi sebesar 95,85% serta runtime tercepat sebesar 0,0235 detik. Selain itu, hasil *feature importance* dan *error analysis* menunjukkan bahwa normalisasi *character obfuscation* berperan penting dalam meningkatkan kemampuan model untuk mengenali keyword promosi judi online dan mengurangi kesalahan klasifikasi.

4.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, penelitian selanjutnya disarankan untuk menggunakan dataset yang lebih besar dan lebih beragam agar model memiliki kemampuan generalisasi yang lebih baik. Selain itu, metode normalisasi *character obfuscation* dapat dikembangkan lebih lanjut dengan menambahkan kamus normalisasi yang lebih luas untuk menangani berbagai variasi Unicode, simbol, dan pola penyamaran karakter yang terus berkembang. Penelitian berikutnya juga dapat membandingkan performa SVM dan MLP dengan metode berbasis *deep learning* maupun *transformer* seperti BERT dan IndoBERT, serta mengembangkan sistem deteksi komentar promosi judi online secara *real-time* untuk mendukung moderasi otomatis pada platform media sosial.

Daftar Pustaka

Samuel, & Kristiadi, D. P. (2025). Deteksi teks promosi judi online menggunakan AI dengan kombinasi NLP dan deep learning. *SINTEK, 5*(2). https://doi.org/10.56995/sintek.v5i2.179

Arroyana, D., et al. (2026). Evaluasi kinerja Random Forest, SVM, dan Transformer untuk klasifikasi komentar judi online di YouTube. *JUSTIN, 14*(1). https://doi.org/10.26418/justin.v14i1.94059

Perdana, R. B., et al. (2024). Detecting online gambling promotions on Indonesian Twitter using text mining algorithm. *International Journal of Advanced Computer Science and Applications, 15*(8). https://doi.org/10.14569/IJACSA.2024.0150893

Alazab, A., et al. (2022). Detection of obfuscated malicious JavaScript code. *Future Internet, 14*(8), 217. https://doi.org/10.3390/fi14080217

Antonius, R., et al. (2024). TF-IDF, SMOTE, and SVM in sentiment classification. *BIT, 2*(3). https://doi.org/10.58369/biit.v2i3.65

Arasy, A., et al. (2025). MLP classification using TF-IDF features. *MALCOM, 5*(3). https://doi.org/10.57152/malcom.v5i3.2052

Alamsyah, A. G., & Hermawan, L. (2024). Obfuscation analysis in malicious code detection. *Jurnal Informatika*. https://ojs.uajy.ac.id/index.php/jbi/article/view/10530

Rifaldi, D., et al. (2023). Text preprocessing on Twitter data. *Decode Journal, 3*(2). https://doi.org/10.51454/decode.v3i2.131

Ode, I., et al. (2026). Spam detection on YouTube comments using Naïve Bayes and KNN. *JIPI*. https://jurnal.stkippgritulungagung.ac.id/index.php/jipi/article/view/7682

Tjahyadi, R., et al. (2023). SVM-based YouTube spam detection system. *JSSTK, 1*(2). https://doi.org/10.24912/jsstk.v1i2.28510

Yaemico. (2024). *Judi Online Dataset*. Kaggle. https://www.kaggle.com/datasets/yaemico/judionline